

卷积神经网络用于近红外光谱预测土壤含水率

王 璨¹, 武新慧¹, 李恋卿², 王玉顺¹, 李志伟^{1*}

1. 山西农业大学工学院, 山西 太谷 030801

2. 南京农业大学资源环境学院, 江苏 南京 210095

摘 要 近红外光谱分析技术在土壤含水率预测方面具有独特的优势, 是一种便捷且有效的方法。卷积神经网络作为高性能的深度学习模型, 能够从复杂光谱数据中自主提取有效特征结构进行学习, 与传统的浅层学习模型相比具有更强的模型表达能力。将卷积神经网络用于近红外光谱预测土壤含水率, 并提出了有效的卷积神经网络光谱回归建模方法, 简化了光谱数据的预处理要求, 且具有更高的光谱预测精度。首先对不同含水率下土壤样品的光谱反射率数据进行简单的预处理, 通过主成分分析减少光谱数据量, 并将处理后的光谱数据变换为二维光谱信息矩阵, 以适应卷积神经网络特殊的学习结构。然后基于卷积神经网络算法, 设置双层卷积和池化结构逐层提取光谱数据的内部特征信息, 并采用局部连接和权值共享减少网络参数、提高泛化性能。通过试验优化网络结构和各项参数, 最终获得针对土壤光谱数据的卷积神经网络土壤含水率预测模型, 并与传统的 BP, PLSR 和 LSSVM 模型进行对比实验。结果表明在训练样本达到一定数量时, 卷积神经网络的预测精度和回归拟合度均高于三种传统模型。在少量训练样本参与建模的情况下, 模型预测表现高于 BP 神经网络, 但略低于 PLSR 和 LSSVM 模型。随着参与训练样本量的增加, 卷积神经网络的预测精度和回归拟合度也随之稳定提升, 达到并显著优于传统模型水平。因此, 卷积神经网络能够利用近红外光谱数据对土壤含水率做出有效预测, 且在较多样本参与建模时取得更好效果。

关键词 卷积神经网络; 近红外光谱; 土壤含水率; 预测模型

中图分类号: TP79

文献标识码: A

DOI: 10.3964/j.issn.1000-0593(2018)01-0036-06

引 言

土壤含水率是土壤理化特性中的一项重要指标。水分作为土壤中作物吸收的主要物质, 与作物的长势和发育状况紧密联系, 是精准农业灌溉所要考虑的主要因素^[1]。因此, 土壤水分的监测一直是农业领域所关注的问题。土壤水分对光谱具有很强的吸收特性, 对土壤光谱反射特征有显著影响^[2]。近红外光谱分析技术在土壤含水率预测方面有独特的优势, 是一种便捷且有效的方法, 有着广泛的研究和应用基础^[3-4]。早期研究发现土壤反射光谱存在由水分所引起的吸收带, 提出可由这些波段的反射率值计算土壤含水率, 随后的研究给出了不同的光谱数据建模方法, 主要有线性回归、反向传播神经网络(backpropagation network, BP)、偏最小二乘回归(partial least squares regression, PLSR)和最小二乘支持向量机(least squares support vector machine, LSS-

VM)^[5-12]。其中 BP, PLSR 和 LSSVM 等模型的预测精度普遍高于线性回归方法, 是目前常用的光谱数据建模方法。通过前人的研究可以发现, 当前近红外光谱预测土壤含水率普遍采用的方法是寻找特征波段, 进而通过上述方法建立预测模型。研究多集中在光谱数据预处理和有效特征波段的筛选方法上, 少见有相关光谱回归模型的提出与改进。而高性能的光谱数据建模方法, 能够简化光谱数据的预处理要求, 同时也是保证光谱预测精度的关键。

卷积神经网络(convolutional neural network, CNN)由 Yann LeCun 提出, Krizhevsky 等^[13]对其进行改进, 在机器学习领域取得了重要的突破。CNN 是一种高性能的深度学习算法, 该构架的提出首先是为了最小化多维数据的预处理要求^[14]。CNN 通过多层卷积和池化操作可以自主学习并提取数据每个局部特征, 获取相对于显式特征提取方法更加有效的抽象特征映射。CNN 目前在图像识别领域表现最为突出^[15], 其他相关基础较少, 但已有研究表明, 利用 CNN 结

收稿日期: 2017-02-17, 修订日期: 2017-07-09

基金项目: 国家重点研发计划(2017YFD0701501), 公益性行业(农业)科研专项(201303095-11)资助

作者简介: 王 璨, 1991 年生, 山西农业大学博士研究生 e-mail: wangcan8206@163.com

* 通讯联系人 e-mail: lizhiweitong@163.com

构对数据进行实值回归也能取得较好效果。

由于 CNN 模型具有从复杂数据中选择并提取有效特征的优点和良好的模型表达能力,因此研究针对不同含水率下黄棕壤的光谱反射率数据集,通过 CNN 模型自主提取特征数据并预测土壤含水率值。首先通过常用光谱预处理及主成分分析降低光谱数据量,然后将样本光谱数据转换成二维光谱信息矩阵,利用 CNN 结构建立土壤含水率预测模型。并与传统的 BP,PLSR 以及 LSSVM 算法进行对比,结果表明卷积神经网络能够取得较好效果,当训练样本超过一定数量时,表现优于当前常用模型。这是一种光谱数据建模新方法,可为相关研究提供基础和借鉴。

1 算法描述

1.1 主成分分析

在对数据建模的过程中,为了加快 CNN 的训练速度,需要减少单一样本的数据量。经过试验表明,虽然采用原始光谱数据参与建模能取得最佳效果,但网络收敛速度较慢,需要更长的训练时间。在保证模型性能的前提下,利用主成分分析(principal component analysis, PCA)方法可以大幅度减少数据量,使模型在高效训练的同时达到所期望的预测能力。PCA 通过一系列线性变换将原始数据转换为一组各维度线性无关的表示。PCA 算法原理和实现步骤已有许多相关研究,此处不再做详细说明。

1.2 二维光谱信息矩阵

由于 CNN 特殊的深度学习结构,需对输入网络的光谱数据进行一些简单的处理。采用构建光谱信息矩阵的方法,将每个样本的光谱数据向量转换为二维光谱信息矩阵,以适应卷积层的相关操作要求,充分发挥模型表达能力。具体处理方法如下:

设 x 为某一样本的光谱数据向量,且为列向量形式,则该样本的二维光谱信息矩阵为

$$S = xx^T \quad (1)$$

假设 x 是三维光谱数据列向量,则一个典型的二维光谱信息矩阵为

$$S = \begin{bmatrix} a_1^2 & a_1 a_2 & a_1 a_3 \\ a_2 a_1 & a_2^2 & a_2 a_3 \\ a_3 a_1 & a_3 a_2 & a_3^2 \end{bmatrix} \quad (2)$$

在统计学中,该方阵是原光谱数据的信息矩阵,其特性是包含数据的所有原始信息,且能够体现数据方差和协方差的相对大小。构建二维光谱信息矩阵能够保持原光谱数据特征和空间关联性,同时符合 CNN 结构的输入要求。在光谱分析方面,二维光谱信息矩阵类似于二维同步相关光谱等高图,其特性是能够从一定程度反映光谱数据的波动情况。更有利于 CNN 学习光谱数据的内部结构,取得更好的模型表达效果。

1.3 卷积神经网络

CNN 通过逐层特征提取学习多维阵列数据内部的本质联系,采用四个关键设计来利用自然信号的属性:局部连接、权值共享、池化和多层网络的使用。作为一种非线性算

法,CNN 与 BP 神经网络具有相同的训练方式,主要区别在于 CNN 具有卷积和池化等特殊结构对输入数据的内部特征进行提取学习。此外,CNN 通过局部连接和权值共享有效减少了网络的训练权值和误差衰减,使多层神经网络的优势得以体现,在网络层数上多于 BP 神经网络。

典型的 CNN 结构如图 1 所示。除输入外的最初两个阶段由卷积层和池化层组成,然后与传统的多层感知器全连接,最后获得输出。




图 1 典型卷积神经网络结构

Fig. 1 The architecture of a typical CNN

卷积层中的单元被组织在特征图中,且每个单元通过一组被称为滤波器的权值与上一层的局部相连接,然后这个局部加权和通过一个非线性函数进行激活。所以卷积层的第 k 个特征图由式(3)定义

$$h_{ij}^k(x) = f((W^k \cdot x)_{ij} + b_k) \quad (3)$$

式(3)中, $h_{ij}^k(x)$ 为特征图中单元的激活值, W^k 是上面提到的局部连接权值, b_k 为偏置值, $f(z)$ 是非线性激活函数,同一特征图中的全部单元共享相同的滤波器。

池化层的作用是对卷积层提取的局部特征进行下采样,减少网络自由参数并提高特征数据的鲁棒性,一般采用均值池化或最大池化方法。池化层由式(4)定义

$$x_d^k = f(\beta_d^k d(x_d^k) + b_l^k) \quad (4)$$

式(4)中: x_d^k 表示相应卷积层特征图 x_d^k 的池化输出, $d(z)$ 是下采样函数, β_d^k 和 b_l^k 分别为乘性偏置和加性偏置。

最后将池化层输出的特征图进行光栅化处理,并与多层感知器(multilayer perceptron, MLP)全连接。通过求解网络损失函数极小化问题来估计网络参数,利用反向传播算法使全部滤波器中的权值得到训练。

2 实验部分

2.1 样本数据采集

以江苏省句容市内采集的农田土壤样本为研究对象,主要土壤类型为黄棕壤,在我国中东部地区分布广泛,具有较强代表性。取样深度为土壤剖面 0~20 cm 范围,采用交叉法在采样范围内取 10 份土样。置土壤样品于室内自然风干,剔除杂质,经研磨后过 2 mm 孔径筛(10 目),放入 105 °C 恒温干燥箱中 48 h。处理完备的土样放入玻璃容器中待用。

制备土壤从饱和到风干状态不同含水率梯度的样品并作光谱测定。方法是从每份土壤样本中取出质量相同的 3 份土样,分别置于大小相同的铝盒中(直径 5 cm,高 1.6 cm),称重后缓慢向其中注水,使土壤样品中的水含量达到轻微过饱和状态。观察并等待土壤表面的自由水完全消失,将土壤表面刮平,开始进行光谱数据的测定。每隔 1 h 对土壤样品进行一次测定,8 h 后根据样本的含水率情况进行最后两次测定。由此得到不同含水率下的土壤光谱反射率数据,同时利用经典的烘干称重法计算土壤含水率。

光谱数据的测定使用美国 ASD FieldSpec3 地物光谱仪,光谱范围 350~2 500 nm,采样间隔为 1.377 nm(350~1 000 nm)和 2 nm(1 000~2 500 nm)。实验在室内进行,采用 5° 视场角探头,距土壤样本表面 25 cm。主动光源为 2 个 50 W 标准卤素灯,置于样本顶部对称的两侧,天顶角为 15°,距土壤样本表面 50 cm。利用白板对光谱仪进行标准化,提高测定精度。对每个样品进行 6 次重复光谱测定,取其平均值作为土壤样本的光谱反射率数据。

根据光谱曲线情况剔除 11 组无效数据,最终获得 289 组有效样品数据,含水率覆盖范围 3.85%~31.72%,样本统计属性如表 1 所示。

表 1 土壤样本含水率统计

Table 1 The statistics of the soil moisture content

样本量	最大值/%	最小值/%	平均值/%	标准差/%
289	31.72	3.85	18.89	2.87

2.2 光谱数据处理

利用 ViewSpec 软件对采集的样本光谱数据进行平滑和拼接校正,并消除其他干扰。经过简单的预处理后,将数据导出。通过 MATLAB R2016b 软件对导出的光谱数据进行 PCA 处理,经过试验,设置主成分数为 20,理论方差累计贡献率达 100%。有效减少了样本数据量,对后期 CNN 建模具有积极意义。将 PCA 后的光谱数据进行归一化处理,并按上述方法变换为光谱信息矩阵,最后每个样本的矩阵大小为 20×20。

2.3 建立预测模型

基于 caffe 深度学习框架建立预测模型,采用 MATLAB 接口进行编程。利用已有样品数据进行反复试验,对网络结构进行改进与调整,以土壤样品光谱信息的最佳回归效果为引导,最终确立土壤含水率的 CNN 预测模型结构,具体结构如图 2 所示。

设置网络第 1 卷积层的卷积核大小为 9×9,数量为 12,激活函数为 RELU(rectified linear units, RELU);第 2 卷积层的卷积核大小为 3×3,数量为 18,每个输出特征图由不同的卷积核在前一层所有特征图上作卷积并将对应元素累加后加偏置,再通过 RELU 函数激活得到;池化层采用均值池化方法,下采样尺度均为 2×2。MLP 隐层神经元个数设置为光栅化层的一半,输出层为单神经元,用于实值回归。网络利用 BP 算法进行训练,设置卷积核权值随机初始化,偏置为全 0 初始化,采用留一交叉验证法选取最佳参数。损失函

数定义为欧氏距离,通过式(5)计算

$$\frac{1}{2N} \sum_{i=1}^N (y_p - y_t)^2 \quad (5)$$

其中 y_p 是网络预测值, y_t 是实验测定值。通过试验设定网络学习率为 0.6,最大迭代次数为 1 000,网络训练过程中的损失函数如图 3 所示。可以看出,网络随着迭代次数的增加逐渐收敛,曲线在宏观上平滑下降,说明学习状态良好,无过拟合状态出现。




图 2 卷积神经网络预测模型结构

Fig 2 The architecture of CNN prediction model




图 3 模型训练过程中的损失函数值

Fig 3 The value of loss function in the process of model training

选用目前研究中常用的 BP, PLSR 和 LSSVM 算法作为对比实验。BP 神经网络选用单隐层结构,PLSR 模型设置为全因子回归,采用留一交叉验证。LSSVM 模型的核函数设置为径向基函数,利用留一交叉验证法确定最佳参数,其中 $\gamma=24.826$, $\sigma^2=3.587$ 。

3 结果与讨论

3.1 预测模型评价

将全部 289 个有效样本划分为训练集和测试集,数据划分规则为所得训练集和测试集具有相似的统计特性。其中训练集样本 202 个用于建立模型,测试集样本 87 个用于检验模型预测性能,训练集占全部样本量的比例为 0.7,交叉验证数据包含在训练集中。进行 5 次重复训练与测试并取平均值,所得结果如表 2 所示。从模型的回归拟合度和预测精度

两个方面考察模型性能,采用的统计评价指标为:建模均方根误差 RMSEC、决定系数 R^2 ;预测均方根误差 RMSEP、决定系数 R_p^2 ;测定值标准差与标准预测误差的比值 RPD。已有研究表明,决定系数、RPD 越大,均方根误差越小,说明预测模型的性能越好,反之则越差。

表 2 不同模型下的土壤含水率预测结果
Table 2 The predicted results of soil moisture content under different model

模型	建模样本		预测样本		
	R^2	RMSEC	R_p^2	RMSEP	RPD
CNN	0.968	0.570	0.956	0.804	3.358
BP	0.947	0.931	0.887	1.432	2.516
PLSR	0.944	1.041	0.928	1.190	2.827
LSSVM	0.951	0.833	0.933	0.995	2.952

由表 2 可知,对相同光谱数据的土壤含水率的回归预测,CNN 模型所取得的效果优于 BP,PLSR 和 LSSVM 模型。在建模样本的回归拟合度和精度方面:CNN 模型的决定系数最大, R^2 为 0.968,均方根误差最小,RMSEC 为 0.570,表现最佳;PLSR 模型的决定系数最小,均方根误差最大,在所有模型中表现较差;BP 和 LSSVM 在 4 个模型中表现中等。CNN 与 BP,PLSR 和 LSSVM 模型相比,在同样样本光谱数据和相同预处理方式的条件下具有最好的建模效果,相关指标均优于传统模型。表明 CNN 模型对于训练样本具有较高的回归拟合优度与回归精度,学习能力较强,能够通过已有数据达到最大程度的训练,同时准确逼近训练样本的实际测定值。模型对于预测样本的回归拟合度和精度是衡量模型性能最重要的方面,反映模型在训练后对于未知样本的预测能力。其中 CNN 模型的预测决定系数最大, R_p^2 为 0.956,比 BP,PLSR 和 LSSVM 模型分别提高 0.069,0.028 和 0.017,具有最大的回归拟合度;均方根误差最小,RMSEP 为 0.804,比 BP,PLSR 和 LSSVM 模型分别降低 0.628,0.386 和 0.191;RPD 值最大,达到 3.358,比 BP,PLSR 和 LSSVM 模型分别提高 0.842,0.531 和 0.406,整体来说预测精度提高较为明显。表明 CNN 模型能够对测试

集样本做出精确的预测,回归拟合度与精度均达到较高水平,在所有测试模型中表现最佳。一般情况下,模型对于预测样本的回归拟合度与预测精度要低于建模样本,两者间差异越小则模型的泛化能力越强。观察表 2 中各模型的评价数据可以看出,CNN 模型的实际预测能力和建模效果最为接近,差异最小,说明 CNN 模型的鲁棒性和实际泛化性能要优于传统模型。在三种传统模型中,BP 神经网络与 CNN 具有相似的训练方式,但实际预测能力远低于建模效果,在泛化性能方面表现不佳。这说明 CNN 模型局部连接和权值共享的特殊网络结构能够增强模型的泛化能力,在实际应用中具有更大的优势。

通过以上分析,CNN 模型能够用于近红外光谱预测土壤含水率,而且相比于 BP,PLSR 和 LSSVM 模型具有更高的回归拟合度和预测精度。采用 CNN 建模方法能够在有效简化光谱数据预处理过程的同时达到更好的回归效果,是一种高性能的土壤含水率预测模型。研究表明 CNN 模型独特的深度学习结构可以提取并学习光谱数据的内部特征,获取更加有效和细致的局部抽象特征映射,利用这些数据特征进行土壤含水率的实值回归能取得更好的效果。此外,CNN 模型的网络组成方式能够降低不相关数据的干扰,提高模型的鲁棒性和实际泛化能力,具有更稳定的光谱预测效果。传统的预测模型并不具备 CNN 的数据特征分析提取过程,在训练前需要对光谱数据进行人工筛选和更多的预处理过程,所以在模型性能上不如 CNN,但是表现也较为良好。CNN 模型的多层网络结构决定了其需要更多的样本来进行训练。当训练样本较少时,可能效果并不理想,随着训练集样本量的增加,模型预测能力也将得到进一步提升。

3.2 建模样本量对模型预测精度的影响

为了研究不同的训练集样本量对 CNN 建模效果的影响,采用相同的规则对训练集和测试集重新划分,进行建模实验并计算相关评价指标,同时进行 BP,PLSR 和 LSSVM 模型的对比实验。训练集样本占全部样本的比例为 0.5~0.9,只对测试集样本的回归拟合度和预测精度进行评价,取 5 次重复试验的平均值一所得结果如表 3 所示。

表 3 不同训练集样本量下各模型的预测结果

Table 3 The predicted results of training sets with different sample sizes

训练集/测试集	CNN			BP			PLSR			LSSVM		
	R_p^2	RMSEP	RPD	R_p^2	RMSEP	RPD	R_p^2	RMSEP	RPD	R_p^2	RMSEP	RPD
(0.5)144/145	0.894	1.676	2.290	0.875	1.726	2.030	0.909	1.579	2.201	0.915	1.256	2.419
(0.6)173/116	0.913	1.334	2.387	0.889	1.554	2.237	0.912	1.285	2.592	0.926	1.091	2.541
(0.7)202/87	0.956	0.804	3.358	0.887	1.432	2.516	0.928	1.190	2.827	0.933	0.995	2.952
(0.8)231/58	0.970	0.614	3.712	0.909	1.498	2.582	0.948	0.852	3.143	0.932	0.863	3.307
(0.9)260/29	0.981	0.545	4.275	0.912	1.131	2.714	0.942	0.869	3.064	0.952	0.792	3.416

根据模型评价原则,通过对比表 3 中数据可知,当训练集比例为 0.5 时,CNN 模型的回归拟合度和预测精度不如 PLSR 和 LSSVM 模型,但优于 BP 神经网络,其中 LSSVM 模型效果最好。当训练集比例为 0.6 时,CNN 模型与 PLSR

模型具有相似的预测能力,但实际表现仍不如 LSSVM 模型。随着训练集所占比例的增加,各模型的性能均有所提升,其中 CNN 模型的提升幅度最为明显。当训练集所占比例大于等于 0.7 以后,CNN 模型在所有模型中表现最佳,各

项指标均在一定程度上优于 BP, PLSR 和 LSSVM 模型。




图 4 各模型的预测决定系数

Fig 4 The prediction R^2 of each model

同时对各模型的预测决定系数变化情况进行比较,如图 4 所示。CNN 模型的预测决定系数随着训练样本的增加而持续增大,在所有模型中增长幅度最大。PLSR 和 LSSVM 模型的增长幅度较小,且出现停止增长的情况。BP 神经网络虽然也有增长,但其预测决定系数始终低于其他模型。总体来说, CNN 模型能够从增长的样本光谱数据中获取更多的有利信息以快速提高模型性能。说明 CNN 模型在有较多样本参与建模的情况下,能够显著提高回归拟合度,性能大幅优于传统模型。在大数据环境下是一种更为有效的光谱回归建模方法,能够基于光谱数据做出更加精确的预测。

4 结 论

将卷积神经网络用于近红外光谱预测土壤含水率,提出了有效的 CNN 光谱数据回归建模方法,并取得了较好效果。首先对不同含水率下土壤的光谱反射率数据进行常用的预处理以及主成分分析处理,减少光谱数据量。将处理后的光谱数据转换为二维光谱信息矩阵,以适应 CNN 模型特殊的深度学习结构,并保持原数据的特征信息和空间关联性。所建 CNN 回归模型利用卷积和池化操作逐层提取数据的抽象特征映射,从而学习数据内部的结构特征及其本质联系。通过局部连接和权值共享的网络结构减少自由参数,提升模型泛化能力。通过试验改进与调整网络参数,得到高性能的 CNN 光谱回归预测模型。利用该模型对土壤含水率进行预测,并与 BP, PLSR 和 LSSVM 模型进行对比。在训练样本达到一定数量时,其预测精度和回归拟合度均高于传统模型,且具有更强的泛化性能。少量训练样本参与建模的情况下模型性能优于 BP,但略低于 PLSR 和 LSSVM。随着训练数据量的增加, CNN 模型的预测能力稳步提升,达到并显著优于传统模型水平。因此, CNN 模型对于大样本量的光谱数据进行回归建模能取得更好的效果,在大数据环境下更具优势。不足之处在于建模所需时间较长,可通过并行运算等技术手段来弥补这一缺点,能够大幅提升卷积神经网络的训练速度。未来卷积神经网络在近红外光谱检测领域会有更加优秀的表现和更为广泛的应用。

References

- [1] Ge Y F, Morgan C L S, Ackerson J P. Geoderma, 2014, (221-222): 61.
- [2] Susha Lekshmi S U, Singh D N, Baghini M S. Measurement, 2014, 54: 92.
- [3] Soriano-Disla J M, Janik L J, Viscarra Rossel R A, et al. Applied Spectroscopy Reviews, 2014, 49(2): 139.
- [4] LIU Yan-de, XIONG Song-sheng, LIU De-li(刘燕德, 熊松盛, 刘德力). Spectroscopy and Spectral Analysis(光谱学与光谱分析), 2014, 34(10): 2639.
- [5] Qiu Y, Fu B, Wang J, et al. Journal of Arid Environments, 2010, 74(2): 208.
- [6] Ahmad S, Kalra A, Stephen H. Advances in Water Resources, 2010, 33(1): 69.
- [7] Shi T, Cui L, Wang J, et al. Plant and Soil, 2013, 366(1-2): 363.
- [8] Mouazen A M, Kuang B, De Baerdemaeker J, et al. Geoderma, 2010, 158(1): 23.
- [9] WANG Hai-jiang, ZHANG Hua-ling, REN Shao-ting, et al(王海江, 张花玲, 任少亭, 等). Transactions of the Chinese Society for Agricultural Machinery(农业机械学报), 2014, 45(7): 133.
- [10] YU Lei, ZHU Ya-xing, HONG Yong-sheng, et al(于雷, 朱亚星, 洪永胜, 等). Transactions of the Chinese Society of Agricultural Engineering(农业工程学报), 2016, 32(22): 138.
- [11] Morellos A, Pantazi X E, Moshou D, et al. Biosystems Engineering, 2016, 152: 104.
- [12] Krizhevsky A, Sutskever I, Hinton G E. ImageNet Classification with Deep Convolutional Neural Networks, Neural Information Processing Systems (NIPS 2012), 2012. 1097.
- [13] LeCun Y, Bengio Y, Hinton G E. Nature, 2015, 521(7553): 436.
- [14] Szegedy C, Liu W, Jia Y, et al. Going Deeper with Convolutions. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015. 1.
- [15] Sun Y, Wang X G, Tang X O. Deep Convolutional Network Cascade for Facial Point Detection. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2013. 3476.

Convolutional Neural Network Application in Prediction of Soil Moisture Content

WANG Can¹, WU Xin-hui¹, LI Lian-qing², WANG Yu-shun¹, LI Zhi-wei^{1*}

1. College of Engineering, Shanxi Agricultural University, Taigu 030801, China

2. College of Resources and Environmental Sciences, Nanjing Agricultural University, Nanjing 210095, China

Abstract The technology of near infrared spectroscopy that has unique advantage in the prediction of soil moisture content is a convenient and effective method. Convolutional neural network (CNN) is a deep learning model with high performance. Using CNN, effective features data can be extracted from complex spectral data and the inner structure of feature data can be learned. Compared with traditional surface learning models, convolutional neural network has more powerful modeling capability. In this research, the CNN was used to predict the soil moisture content by near infrared spectroscopy. An efficient modeling method of CNN for spectral regression was proposed. The pretreatment process of spectral data was simplified and the accuracy of spectral prediction was improved by this modeling method. In this paper, firstly, the simple pretreatment was used to treat the spectral reflectance data of soil samples under different moisture contents. Principal component analysis was used to reduce the amount of spectral data and the correlation of the features. The processed spectral data was transformed into 2-dimensional spectral information matrixes to meet the special learning structure of CNN. Secondly, the convolutional neural network was used to build the regression model for the prediction of soil moisture content. The first four stages of this CNN model were composed of two types of layers: convolutional layers and pooling layers. Inner features of the input spectral data were obtained by composing convolutional layers and pooling layers, each transforms the representation at one level into a representation at a higher, slightly more abstract level. With the composition of enough such transformations, very effective inner features of spectral data can be extracted. There were two key ideas behind the CNN model that can reduce the number of parameters of the network: local connections and shared weights. In addition, these ideas can also improve the generalization performance of the CNN model. The model structure and parameters were optimized by carrying out experiments. Finally, the CNN model with improved regression structure of soil spectral data was built for the prediction of soil moisture content. The CNN model was compared with the BP, PLSR and LSSVM models, and these three traditional models were commonly used in the prediction of soil moisture content. The results showed that when the number of training samples reached to some degree, the prediction accuracy and regression fitting degree of the CNN model were higher than those of the traditional models. The performance of the CNN model were much higher than the BP neural network which had the same network training method with the CNN model, but slightly lower than the PLSR and LSSVM models when a small number of training samples were used in the modeling. The prediction accuracy of the CNN model greatly increased with the number of training samples growing. So did the regression fitting degree of the CNN model. In the end, the performance of the CNN model was significantly better than the traditional models. Therefore, the CNN method could be used to effectively predict the soil moisture content by the near infrared spectral data, and better results are obtained when more training samples are involved in modeling.

Keywords Convolutional neural network; Near infrared spectroscopy; Soil moisture content; Prediction model

(Received Feb. 17, 2017; accepted Jul. 9, 2017)

* Corresponding author